

MODELO PREDICTIVO PARA LA DETECCIÓN DE SITIOS WEB MALICIOSOS

Phishing Website Detection Model

Arnoldo Treviño Ceja



www.ubiqra.com



artrevino@ubiqra.com




Tabla de Contenido

1	Portada
2	Indice
3	Introducción
4	Objetivo
5	Descripción del problema
6	Metodología de análisis
7	Preparación de los datos
8	Definición de los datos
9-10	Tipos de datos esperados
11	Selección de características
12	Conjunto de datos
13	Proceso de datos exploratorio EDA
14	Proceso de transformación y limpieza de datos (ETL)
15-16	Selección y adecuación del modelo
17-18	Análisis de resultados
19-22	Flujo de trabajo Knime
23-35	Visualización de datos
36	Conclusión y Reflexión final.



Introducción

Actualmente, la Inteligencia Artificial avanza a un ritmo exponencial, lo que hace indispensable mantenerse alineados y actualizados con sus nuevas capacidades y formas de operación. Gracias al uso de sensores avanzados y al poder de procesamiento de GPUs y TPUs, hoy es posible ejecutar millones de transacciones de datos en tiempo récord y realizar cálculos de una complejidad sin precedentes.

El aprendizaje automático ha evolucionado significativamente, incorporando nuevas técnicas que han transformado la forma en que analizamos, predecimos y automatizamos procesos, rompiendo paradigmas y redefiniendo los límites de lo que creíamos posible.




Objetivo



Desarrollar e implementar un modelo de machine learning capaz de detectar sitios web de phishing con al menos un 90% de precisión y un AUC superior a 0.90 en un periodo de 3 meses.



Descripción: Identificación y delimitación del problema



Muchas empresas, PYMES y emprendedores sufren ataques de ingeniería social y phishing debido a la falta de concientización de sus empleados. Estos ataques comprometen información confidencial, generan pérdidas económicas y deterioran la reputación corporativa. Hay que enfocarse en como minimizar esas pérdidas porque sabemos que la mayoría de los ataques que resultan exitosos siempre hay un humano que abre la brecha para que esto suceda.




Los cibercriminales aprovechan la debilidad humana para engañar y robar información sensible. Según Welivesecurity los ciber incidentes en Latam, aumentaron 25% cada año los últimos 10 años por lo que estamos hablando de un 250% ahora si el 70% es por ingeniería social es ahí donde tenemos que minorizar la probabilidad de recibir un ataque de ingeniería social y para eso se ocupa concientizar a las personas a través del entrenamiento y aprendizaje.



El problema seleccionado para este proyecto es el análisis y la detección de intentos de ataque de sitios web de phishing. Estos ataques consisten en intentos maliciosos de engañar a personas u organizaciones para que revelen información confidencial, como contraseñas o datos de tarjetas de crédito. Este es un problema típico de modelo de aprendizaje supervisado ya que se utilizarán clasificadores para detección de phishing, esto ayuda a las empresas a comprender los patrones de un ataque de phishing y a mejorar sus herramientas anti-phishing.

Metodología de Analisis



Análisis Exploratorio de Datos EDA

Comprendimos la estructura de los datos, identificando relaciones y anomalías. Transformación y normalización para limpieza y comprensión de patrones.



Modelo Supervisado

Aplicamos algoritmos avanzados para descubrir patrones y hacer predicciones.



Optimización de Hiperparámetros

Afinamos los modelos para maximizar la precisión y robustez de las predicciones.




Proceso ETL

Limpieza y preparación automática de datos imperfectos. Se verifica la calidad de los datos utilizando un nodo "Missing Value" para tratar los valores faltantes, asegurando que el modelo reciba datos completos y precisos

Preparación de los datos

- 01 Este conjunto de datos está diseñado para facilitar el análisis y la detección de sitios web de phishing. Contiene diversas características que permiten distinguir entre sitios web legítimos y de phishing según sus atributos estructurales, de seguridad y de comportamiento.



Características basadas en el comportamiento:

- Mouse_over– Comprueba si el sitio web cambia su contenido cuando se pasa el cursor sobre él (se utiliza en técnicas engañosas).
- Right_Click– Detecta si la funcionalidad de clic derecho está deshabilitada (los sitios de phishing pueden deshabilitarla).
- popUpWindow– Identifica la presencia de ventanas emergentes que pueden utilizarse para engañar a los usuarios.
- IFrame– Comprueba si el sitio web utiliza <iframe>etiquetas, a menudo utilizadas en ataques de phishing.

Definición de los datos

Funciones basadas en páginas web:

- Favicon– Determina si el sitio web utiliza un favicon externo (lo que puede ser una señal de phishing).
- port– Identifica si el sitio está utilizando puertos sospechosos o no estándar.
- HTTPS_Token– Comprueba si "HTTPS" está incluido en la URL, pero se utiliza de forma engañosa.
- Request_URL– Mide el porcentaje de recursos externos cargados desde diferentes dominios.
- URL_of_Anchor– Analiza las etiquetas de anclaje (<a>enlaces) y su confiabilidad.
- Links_in_tags– Examina las etiquetas <meta>, <script>, y <link>en busca de enlaces externos.
- SFH (Manejador de formulario del servidor): Determina si las acciones del formulario se manejan de manera sospechosa.
- Submitting_to_email– Comprueba si los formularios envían datos directamente a un correo electrónico en lugar de a un servidor web.
- Abnormal_URL– Identifica si la estructura de la URL del sitio web es inconsistente con los patrones comunes.
- Redirect– Cuenta la cantidad de redirecciones; los sitios web de phishing pueden tener redirecciones excesivas.

Tipos de datos esperados

Funciones basadas en URL:

- Prefix_Suffix– Comprueba si la URL contiene un guion (-), que se utiliza comúnmente en dominios de phishing.
- double_slash_redirecting– Detecta si la URL redirecciona mediante //, lo que puede indicar un intento de phishing.
- Have_At– Identifica la presencia de @ en la URL, que puede utilizarse para engañar a los usuarios.
- Shortening_Service– Indica si la URL utiliza un servicio de acortamiento (por ejemplo, bit.ly, tinyurl).
- URL_Length– Mide la longitud de la URL; las URL de phishing tienden a ser más largas.
- Have_IP Comprueba si se utiliza una dirección IP en lugar de un nombre de dominio, lo cual es sospechoso.

Funciones basadas en dominios:

- having_Sub_Domain– Evalúa la cantidad de subdominios; los sitios de phishing a menudo tienen subdominios excesivos.
- SSLfinal_State– Indica si el sitio web tiene un certificado SSL válido (conexión segura).
- Domain_registration_length– Mide la duración del registro del dominio; los sitios de phishing suelen tener una vida útil corta.
- Domain_Age– La antigüedad del dominio en días; los dominios más antiguos suelen ser más confiables.
- DNS_Record– Comprueba si el dominio tiene registros DNS válidos; los dominios de phishing pueden no tenerlos.

Tipos de datos esperados



Características de tráfico y motores de búsqueda:

- Web_Traffic– Mide la clasificación de Alexa del sitio web; los sitios de phishing tienden a tener poco tráfico.
- Page_Rank– Puntuación PageRank de Google; los sitios de phishing suelen tener un PageRank bajo.
- Google_Index– Comprueba si el sitio web está indexado por Google (es posible que los sitios de phishing no estén indexados).
- Links_pointing_to_page– Cuenta el número de back links que apuntan al sitio web.
- Statistical_report– Utiliza fuentes externas para verificar si el sitio web ha sido denunciado por phishing.

Variable objetivo:

- Result– La etiqueta de clasificación (1: Legítimo, -1: Phishing)



Selección de características


Todas las características de URL's y Dominios se consideran potencialmente relevantes, así como las características basadas en el comportamiento, las características basadas en el tráfico y motores de búsqueda y ciertas funciones basadas en sitios web.

Proceso de selección

- Para el proceso de selección se analizaron los 31 parámetros del dataset primario y se consideraron muy relevantes para el desarrollo del modelo puesto que los parámetros incluyen URL's, Dominios, tráfico, motores de búsqueda, funciones y características de comportamiento y de páginas web.
- El segundo dataset consta de 18 parámetros de los cuales se descartaron 6 parámetros y se incluyeron 12 parámetros que tenían en común con el dataset primario, se homologaron los títulos y sus valores.

Características relevantes

- | | |
|----------------------|----------------|
| • Have_IP | • Web_Traffic |
| • URL_Length | • Mouse_over |
| • Shortining_Service | • Right_Click |
| • Prefix_Suffix | • Google_Index |
| • HTTPS_Token | • Page_Rank |
| • DNS_Record | • IFrame |
| • HTTPS_Token | • Result. |
| • Favicon | |



Conjunto de datos

Recolección de datos

01



Dataset utilizado:

- El conjunto de datos "Datos de Phishing" es una recopilación completa de información seleccionada específicamente para analizar y comprender los ataques de phishing.
- Datos de sitios web de phishing.csv y 5.urldata.csv (conjunto de datos recopilados de kaggle para su estudio y evaluación, los cuales entre ambos dataset muestran 20,000 mil registros con 30 parámetros para su análisis.).
- <https://www.kaggle.com/datasets/sai10py/phishing-websites-data>
<https://www.kaggle.com/datasets/hasibur013/url-data-for-phishing-website-detection>

02

Carga de datos

- Se cargan los datos usando el nodo "File Reader". Se elige este nodo por su eficiencia en la carga y su capacidad para manejar varios formatos de datos. En este proceso de datos primero se realizó una unión de dos dataset en uno mismo homologando los parámetros más relevantes y comunes.



Proceso de análisis exploratorio de datos (EDA)

Transformación de datos

03




Análisis exploratorio de datos (EDA), transformación y normalización para limpieza y comprensión de patrones. (visualización de datos). El dataset principal consta de 31 parametros de los cuales 11 parámetros eran iguales al dataset secundario y uno más es la variable objetivo que tenía el valor resultante cambiado. Recordemos que la variable objetivo Result es la etiqueta de clasificación en el cual los valores resultantes son (1: Legítimo, -1: Phishing), por otra parte, en el dataset secundario la variable resultante estaba de la siguiente manera (0: Legítimo, 1: Phishing), como verán los resultados estaban cambiados por lo que se decidió utilizar el nodo Rule Engine para cambiar el valor resultante de la variable Result de la siguiente manera:

$\$Result\$ = 0 \Rightarrow 1$

$\$Result\$ = 1 \Rightarrow -1$

$TRUE \Rightarrow \$Result\$$

Así la variable objetivo Result queda con los valores homologados y anexados en el conjunto de datos, por lo que después de hacer esto tenemos 12 parámetros de 31 homologados. Para los 19 parámetros faltantes se procedió a agregarlos uno por uno a través del nodo Constant Value Column y aplicando un nodo Column Resorter para cada dataset y poder reordenarlos, para así tener homologados los 31 parámetros en ambos dataset, después se aplica un nodo Concatenate para unir los dataset dando un total de 20,000 columnas. y un nodo Missing Value para rellenar los datos faltantes.



Proceso de transformación y limpieza de datos (ETL)



Limpieza de datos:

- Proceso ETL para limpieza y preparación automática de datos imperfectos.
- Se verifica la calidad de los datos utilizando un nodo "Missing Value" para tratar los valores faltantes, asegurando que el modelo reciba datos completos y precisos.
- Se convierten los datos de número en formatos de tipo string con el nodo Number to String para el adecuado modelado de los datos.



Selección de características:

Como se mencionó anteriormente, se realiza un análisis, transformación y limpieza de los datos para identificar los parámetros más relevantes de URL's y de Dominio, así como las características basadas en el comportamiento, las características basadas en el tráfico y motores de búsqueda y ciertas funciones basadas en sitios web.




Selección y adecuación del modelo



Modelado de datos:

Se utilizara la plataforma KNIME para evaluar la predicción de si un sitio web es engañoso o fraudulento (Phishing), a través del entrenamiento de los modelos de clasificación y mediante aprendizaje supervisado. Se utilizarán los siguientes nodos:


- **Decision Tree Learner**



- **XGBoost Tree Ensemble**




- **Random Forest Learner**



- **Naive Bayes Learner**



- **Logistic Regression Learner**




Selección y adecuación del modelo



Modelado de datos:

Modelo supervisado que clasifica en dos categorías: Phishing y No Phishing. Se implementará un análisis de los modelos entrenados y se compararan los resultados entre los modelos para definir qué modelo es el más apropiado y fiable para la detección de phishing.

- Decisión Tree
- Random Forest
- XGBoost
- Bayesiano
- Logistic Regression



Análisis de resultados



Evaluación del modelo:

Se emplea el nodo "Scorer" para evaluar el rendimiento de los modelos basado en métricas como:

- **La matriz de confusión:** Para ver falsos positivos, falsos negativos, verdaderos positivos y negativos.
- **Métricas globales como Accuracy** que mide la precisión general del modelo y el **Cohen's Kappa** que nos dice que tan fiable es nuestro modelo.
- **Métricas de clasificación:** Clasifica si es phishing o no
- **Sensitivity y Recall:** Miden la eficacia de detectar eventos positivos
- **Precisión:** Mide la eficacia del modelo para asignar eventos positivos a la clase positiva. Es decir, la precisión de la predicción de phishing.
- **F-Measure (F1):** Mide el rendimiento del modelo de clasificación combinando la Precisión y el Recall (también llamado sensibilidad o tasa de **verdaderos positivos**).




Análisis de resultados


- **Curva ROC:** Mide el rendimiento del modelo de clasificación binaria a través del AUC que es una medida de la capacidad del modelo para distinguir entre las clases positiva y negativa.
- **La FPR (1 - especificidad):** indica la proporción de instancias negativas que el modelo clasifica incorrectamente como positivas.
- **Comparación de métricas** por modelo y por clase entre modelos
- **Curva ROC Superpuesta:** Métrica global entre modelos para comparación
- **Métrica de importancia de atributos:** Mide cuales son los atributos más importantes que se deberían de tomar en cuenta se utiliza el nodo Global Feature Importance, esto sirve para la interpretabilidad de las variables del modelo.
- **Gráfico de AUC entre modelos:** Compara el Area Under Curve de los modelos.




Flujo de trabajo en Knime





Flujo modelo Desicion Tree




Flujo modelo Naive Bayes



Flujo modelo Logistic Regression Flujo modelo Random Forest



Flujo modelo XGBoost Tree Ensemble




VISUALIZACIÓN DE DATOS




Finalmente, se crean los siguientes gráficos para cada modelo para su interpretación, comparación, rendimiento, matriz de confusión, Curva AUC, precisión y tendencias. Para esto se utilizarán los siguientes nodos:


- **Pie Chart**




- **Bar Chart (JavaScript (legacy))**



- **Generic JavaScript View (JavaScript) (legacy)**





- **Roc Curve (JavaScript) (legacy)**



- **Scorer (JavaScript)**



- **Scatter Plot**



RESULTADOS

Decision Tree Learner

Scorer View

Decision Tree

Confusion Matrix

Rows Number : 6317	1 (Predicted)	-1 (Predicted)	
1 (Actual)	3154	161	95.14%
-1 (Actual)	596	2406	80.15%
	84.11%	93.73%	

Class Statistics


Class	True Positives	False Positives	True Negatives	False Negatives	Recall	Precision	Sensitivity	Specificity	F-measure
1	3154	596	2406	161	95.14%	84.11%	95.14%	80.15%	89.29%
-1	2406	161	3154	596	80.15%	93.73%	80.15%	95.14%	86.41%

Overall Statistics


Overall Accuracy	Overall Error	Cohen's kappa (κ)	Correctly Classified	Incorrectly Classified
88.02%	11.98%	0.758	5560	757

Resultados: Modelo Árbol de Decisión


ACCURACY




ERROR %




COHEN'S KAPPA




RECALL




PRECISIÓN




F1-SCORE




Métricas por Clase




Distribución de Phishing




Métricas Globales AUC y Kappa



ROC CURVE (AUC)



Matriz de Confusión




RESULTADOS

Naive Bayes Learner

Scorer View

Naive Bayes



Confusion Matrix

Rows Number : 6317	1 (Predicted)	-1 (Predicted)	
1 (Actual)	1788	1527	53.94%
-1 (Actual)	674	2328	77.55%
	72.62%	60.39%	

Class Statistics


Class	True Positives	False Positives	True Negatives	False Negatives	Recall	Precision	Sensitivity	Specificity	F-measure
1	1788	674	2328	1527	53.94%	72.62%	53.94%	77.55%	61.90%
-1	2328	1527	1788	674	77.55%	60.39%	77.55%	53.94%	67.90%

Overall Statistics


Overall Accuracy	Overall Error	Cohen's kappa (κ)	Correctly Classified	Incorrectly Classified
65.16%	34.84%	0.311	4116	2201

Resultados: Modelo Bayesiano


ACCURACY




ERROR %




COHEN'S KAPPA




RECALL




PRECISIÓN




F1-SCORE




Métricas por Clase




Distribución de Phishing




Métricas Globales AUC y Kappa



ROC CURVE (AUC)



Matriz de Confusión




RESULTADOS

Logistic Regression Learner

Scorer View

Logistic Regression



Confusion Matrix

Rows Number : 6317	1 (Predicted)	-1 (Predicted)	
1 (Actual)	3037	278	91.61%
-1 (Actual)	860	2142	71.35%
	77.93%	88.51%	

Class Statistics


Class	True Positives	False Positives	True Negatives	False Negatives	Recall	Precision	Sensitivity	Specificity	F-measure
1	3037	860	2142	278	91.61%	77.93%	91.61%	71.35%	84.22%
-1	2142	278	3037	860	71.35%	88.51%	71.35%	91.61%	79.01%

Overall Statistics


Overall Accuracy	Overall Error	Cohen's kappa (κ)	Correctly Classified	Incorrectly Classified
81.99%	18.01%	0.635	5179	1138

Resultados: Modelo Regresión Logística


ACCURACY




ERROR %




COHEN'S KAPPA




RECALL



PRECISIÓN




F1-SCORE




Métricas por Clase




Distribución de Phishing




Métricas Globales AUC y Kappa



ROC CURVE (AUC)



Matriz de Confusión



RESULTADOS

Random Forest Learner

Scorer View

Random Forest

Confusion Matrix

Rows Number : 6317	1 (Predicted)	-1 (Predicted)	
1 (Actual)	3244	71	97.86%
-1 (Actual)	713	2289	76.25%
	81.98%	96.99%	

Class Statistics


Class	True Positives	False Positives	True Negatives	False Negatives	Recall	Precision	Sensitivity	Specificity	F-measure
1	3244	713	2289	71	97.86%	81.98%	97.86%	76.25%	89.22%
-1	2289	71	3244	713	76.25%	96.99%	76.25%	97.86%	85.38%

Overall Statistics


Overall Accuracy	Overall Error	Cohen's kappa (κ)	Correctly Classified	Incorrectly Classified
87.59%	12.41%	0.749	5533	784

Resultados: Modelo Bosque Aleatorio


ACCURACY




ERROR %




COHEN'S KAPPA




RECALL




PRECISIÓN




F1-SCORE




Métricas por Clase




Distribución de Phishing




Métricas Globales AUC y Kappa



ROC CURVE (AUC)



Matriz de Confusión



RESULTADOS

XGBoost Tree Ensemble

Scorer View

XGBoost

Confusion Matrix

Rows Number : 6317	1 (Predicted)	-1 (Predicted)	
1 (Actual)	3195	120	96.38%
-1 (Actual)	576	2426	80.81%
	84.73%	95.29%	

Class Statistics


Class	True Positives	False Positives	True Negatives	False Negatives	Recall	Precision	Sensitivity	Specificity	F-measure
1	3195	576	2426	120	96.38%	84.73%	96.38%	80.81%	90.18%
-1	2426	120	3195	576	80.81%	95.29%	80.81%	96.38%	87.45%

Overall Statistics


Overall Accuracy	Overall Error	Cohen's kappa (κ)	Correctly Classified	Incorrectly Classified
88.98%	11.02%	0.778	5621	696

Resultados: Modelo XGBoost


ACCURACY




ERROR %




COHEN'S KAPPA




RECALL




PRECISIÓN




F1-SCORE




Métricas por Clase




Distribución de Phishing




Métricas Globales AUC y Kappa



ROC CURVE (AUC)



Matriz de Confusión



Resultados: Modelo con Mejor Rendimiento XGBOOST

PRECISIÓN

90 %

RECALL

88.6 %

ESPECIFICITY

87.1 %

COHEN’S KAPPA

77.8 %

ERROR %

11 %

ACCURACY

89 %

F1-SCORE


88.8 %

AUC

88.8 %

FPR False Positive Rate

FPR (False Positive Rate) por Modelo



Comparación de Resultados

Modelo	Accuracy	Precision	Recall	F1-score	AUC	Error %
XGBoost	0.89	0.90	0.886	0.888	0.949	11%
Decisión Tree	0.88	0.889	0.876	0.878	0.938	11.9%
Random Forest	0.876	0.895	0.871	0.873	0.901	12.4%



Mejor Modelo
XGBoost




Aprendizaje
Supervisado




Metodo
Clasificación


AUC Global por modelo




Importancia de atributos




Grafica de Dispersión AUC



Curva superpuesta ROC




Métricas por Modelos




Curvas ROC


XGBoost



Bosque Aleatorio



Árbol de Decisión



CONCLUSIÓN Y REFLEXIÓN FINAL

En un entorno global en constante transformación, donde las tecnologías evolucionan a una velocidad sin precedentes, la Inteligencia Artificial (IA) ha dejado de ser una tecnología emergente para convertirse en una realidad tangible que impacta todos los sectores. Al igual que en su momento lo fue la Revolución Industrial, la IA se posiciona hoy en el centro de la innovación y el desarrollo. Frente a este escenario, es imperativo que individuos, empresas, instituciones educativas y entidades públicas asuman un rol activo. No se trata de resistirse al cambio, sino de adoptarlo estratégicamente para automatizar procesos, optimizar operaciones y fortalecer modelos educativos.

No obstante, este avance exige también una actualización urgente en los marcos regulatorios: es necesario revisar y adaptar las leyes sobre protección de datos, uso ético de la tecnología y derechos de autor. El desarrollo y aplicación de la IA debe orientarse al bien común, con responsabilidad, ética y transparencia, tal como lo plantea este proyecto.

La IA no reemplaza la inteligencia humana, la potencia.

Muchas gracias

